RELATÓRIO DO TRABALHO PRÁTICO 1 (TP1)

Integração de Resultados de Torneios de Ténis
(ETL em Pentaho PDI & PostgreSQL)

Unidade Curricular:	Integração de Sistemas de Informação (ISI)
Curso / Instituição:	Licenciatura em Engenharia de Sistemas Informáticos (ESI) — UPCA EST
Ano Letivo / Semestre:	2026/2027 — 1.º Semestre
Aluno:	Telmo Silva | A20456 (a20456@alunos.ipca.pt)
Docentes da UC:	Prof. Óscar Ribeiro

Índice

1. Enquadramento 3
2. Problema 3
2.1. Desafios da Fase 1 — Recolha de Fontes Heterogéneas 3
2.2. Desafios da Fase 2 — Anomalias e Necessidade de Cruzamento 4
2.3. Desafios da Fase 3 — Carga, Persistência e Notificação 4
3. Estratégia Utilizada 4
4. Transformações 5
4.1. Transformações da Fase 1 (Recolha - E) 5
4.2. Transformações da Fase 2 (Processamento e Transformação - T) 6
4.3. Transformações da Fase 3 (Carga, Exportação e Notificação - L) 12
5. Jobs 21
5.1. Job da Fase 1 (job_fase1_recolha.kjb) 21
5.2. Job da Fase 2 (job_fase2_transformacao.kjb) 22
5.3. Job da Fase 3 (job_fase3_carga.kjb) 23
6. Vídeo com demonstração (QR Code) 25
7. Conclusão e Trabalhos Futuros 26
7.1. Tabela de Cumprimento de Requisitos do Enunciado 26
7.2. Trabalhos Futuros 26
8. Referências Bibliográficas 27

1. Enquadramento

O presente trabalho prático enquadra-se no âmbito da unidade curricular de **Integração de Sistemas de Informação (ISI)**, lecionada no curso de Licenciatura em Engenharia de Sistemas Informáticos (ESI) da Escola Superior de Tecnologia da Universidade Politécnica do Cávado e do Ave (UPCA).

O projeto tem como tema central a **Integração de resultados de torneios de ténis** e foca-se na aplicação e experimentação de ferramentas de **ETL (Extract, Transform and Load)** inerentes a processos de integração de sistemas ao nível dos dados. A solução desenvolvida recorre ao **Pentaho Data Integration (PDI / Kettle / Spoon)** como ferramenta principal de orquestração e ao **PostgreSQL** como sistema de gestão de base de dados relacional centralizado.

2. Problema

O principal desafio deste trabalho consiste em recolher, tratar, cruzar e disponibilizar os resultados de torneios de ténis provenientes de fontes de dados heterogéneas, superando anomalias e garantindo a persistência centralizada dos dados para apoio à decisão.

2.1. Desafios da Fase 1 — Recolha de Fontes Heterogéneas

Na primeira fase, os dados encontram-se totalmente fragmentados em quatro tipologias de ficheiros locais, sem qualquer ligação entre si:

- **Partidas (CSV):** Contém identificadores da partida, do torneio e dos jogadores, data, ronda, resultado e rankings (data\incoming\partidas.csv).
- **Torneios (JSON):** Contém o nome do torneio, superfície, nível, cidade, país e data de início (data\incoming\torneios.json).
- **Jogadores (XML):** Contém o identificador, nome, país e mão preferencial do jogador (data\incoming\jogadores.xml).
- **Regras de Alerta (YAML):** Define parâmetros de negócio como pais_alerta: POR, ronda_titulo: F e upset_minimo: 30 (data\incoming\regras_alerta.yaml).

2.2. Desafios da Fase 2 — Anomalias e Necessidade de Cruzamento

Os dados recolhidos na área de staging contêm anomalias propositadamente introduzidas e carecem de enriquecimento semântico:

- **Ausência de nomes:** O ficheiro CSV das partidas apenas refere códigos (ex.: torneio 'AO2024', jogador '7'), tornando impossível a leitura direta sem o cruzamento com os ficheiros JSON e XML.
- **Registos duplicados:** A partida id 1 encontra-se repetida no CSV de entrada.
- **Marcadores inválidos:** A partida id 19 apresenta o resultado 'abc', que não constitui um resultado válido de ténis.
- **Inconformidades de texto:** O jogador id 7 encontra-se registado com espaçamento excessivo (' Nuno Borges').

2.3. Desafios da Fase 3 — Carga, Persistência e Notificação

Após a limpeza e transformação, os dados permaneciam isolados em ficheiros intermédios CSV na pasta data\transformado. O desafio final consistiu em persisti-los numa base de dados relacional (tenis_tp1 em PostgreSQL) organizada em 5 tabelas (dim_jogador, dim_torneio, fact_partida, fact_alerta e resumo_jogador), exportar alertas para ficheiro externo e disparar notificações automáticas por e-mail via servidor SMTP.

3. Estratégia Utilizada

A ferramenta de orquestração utilizada é o **Spoon (Pentaho Data Integration)**. A solução adota uma arquitetura modular encadeada dividida em três fases bem delimitadas: **Recolha (E) → Transformação (T) → Carga (L)**.

Cada fase é coordenada por um Job principal (.kjb) que executa as respetivas transformações (.ktr) e invoca o Job da fase anterior, garantindo a sequência lógica e a integridade do fluxo completo.

- **Fase 1 (Recolha - E):** Extração das fontes heterogéneas (CSV, JSON, XML, YAML) e gravação em cópias de staging (CSV) na pasta data\staging, sem aplicar regras de negócio.
- **Fase 2 (Transformação - T):** Remoção de duplicados (Unique rows), validação de marcadores via Regex Evaluation com desvio de inválidos para quarentena (rejeitados.csv), normalização de nomes com regex \s+, cruzamentos via Stream lookup, cálculo de indicadores (upset, título, alerta, motivo) com Java Expression (Janino) e agregação de resumos (Memory group by).
- **Fase 3 (Carga - L):** Persistência relacional das tabelas na base de dados PostgreSQL (tenis_tp1), exportação do ficheiro alertas.csv para data\export e notificação automática de conclusão por e-mail via SMTP.

4. Transformações

Nesta secção apresentam-se detalhadamente as transformações (.ktr) desenvolvidas no Pentaho Spoon, acompanhadas pelos respetivos diagramas e resultados de execução.

4.1. Transformações da Fase 1 (Recolha - E)

A Fase 1 envolve 4 transformações dedicadas à leitura isolada das fontes originais e gravação na pasta staging:

Fonte	Formato	Ficheiro	Transformação	Saída
Partidas	CSV	data\incoming\partidas.csv	recolher_partidas.ktr	staging\partidas_recolhidas.csv
Torneios	JSON	data\incoming\torneios.json	recolher_torneios.ktr	staging\torneios_recolhidas.csv
Jogadores	XML	data\incoming\jogadores.xml	recolher_jogadores.ktr	staging\jogadores_recolhidas.csv
Regras	YAML	data\incoming\regras_alerta.yaml	recolher_regras.ktr	staging\regras_recolhidas.csv

Figura 1 - Formatos

```
2026-10-08 14:10:56.101 - Fase 1 - Recolha - Starting entry [Recolher partidas]
2026-10-08 14:10:56.147 - Recolher partidas - Using run configuration [Pentaho local]
2026-10-08 14:10:56.172 - Carte - Installing timer to purge stale objects after 1440 minutes.
2026-10-08 14:10:56.179 - recolher_partidas - Expedindo in�cio para transforma��o [recolher_partidas]
2026-10-08 14:10:56.281 - Ler partidas.0 - Header row skipped in file 'file:///D:/ISI/TP1/A20456_TP1/Fase_1/kettle/../data/incoming/partidas.csv'
2026-10-08 14:10:56.286 - Ler partidas.0 - Finished processing (I=21, O=0, R=0, W=20, U=0, E=0)
2026-10-08 14:10:56.301 - Gravar recolha.0 - Finished processing (I=0, O=21, R=20, W=20, U=0, E=0)
```

Figura 2 - Execution Results - Partidas

```
2026-10-08 14:10:57.128 - Fase 1 - Recolha - Starting entry [Recolher torneios]
2026-10-08 14:10:57.144 - Recolher torneios - Using run configuration [Pentaho local]
2026-10-08 14:10:57.145 - recolher_torneios - Expedindo in�cio para transforma��o [recolher_torneios]
2026-10-08 14:10:57.450 - Ler torneios.0 - Finished processing (I=5, O=0, R=0, W=5, U=0, E=0)
2026-10-08 14:10:57.454 - Gravar recolha.0 - Finished processing (I=0, O=6, R=5, W=5, U=0, E=0)
```

Figura 3 - Execution Results - Torneios

```
2026-10-08 14:10:58.133 - Fase 1 - Recolha - Starting entry [Recolher jogadores]
2026-10-08 14:10:58.153 - Recolher jogadores - Using run configuration [Pentaho local]
2026-10-08 14:10:58.154 - recolher_jogadores - Expedindo in�cio para transforma��o [recolher_jogadores]
2026-10-08 14:10:58.183 - Ler jogadores.0 - Finished processing (I=12, O=0, R=0, W=12, U=0, E=0)
2026-10-08 14:10:58.188 - Gravar recolha.0 - Finished processing (I=0, O=13, R=12, W=12, U=0, E=0)
```

Figura 4 - Execution Results - Jogadores

```
2026-10-08 14:10:59.138 - Fase 1 - Recolha - Starting entry [Recolher regras]
2026-10-08 14:10:59.156 - Recolher regras - Using run configuration [Pentaho local]
2026-10-08 14:10:59.157 - recolher_regras - Expedindo in�cio para transforma��o [recolher_regras]
2026-10-08 14:10:59.166 - Ler regras.0 - Opening file: file:///D:/ISI/TP1/A20456_TP1/Fase_1/data/incoming/regras_alerta.yaml
2026-10-08 14:10:59.177 - Ler regras.0 - Finished processing (I=3, O=0, R=0, W=3, U=1, E=0)
2026-10-08 14:10:59.184 - Gravar recolha.0 - Finished processing (I=0, O=4, R=3, W=3, U=0, E=0)
```

Figura 5 - Execution Results - Regras

4.2. Transformações da Fase 2 (Processamento e Transformação - T)

A Fase 2 contempla as transformações limpar_jogadores.ktr e transformar_partidas.ktr, responsáveis por corrigir anomalias, validar regras de negócio e realizar cruzamentos entre entidades:

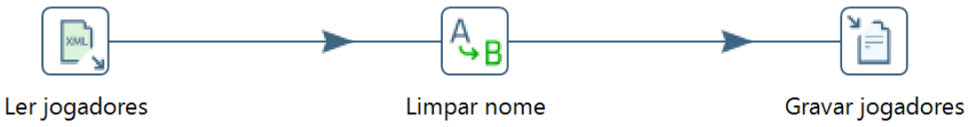


Figura 6 - Fase_2\kettle\limpar_jogadores.ktr

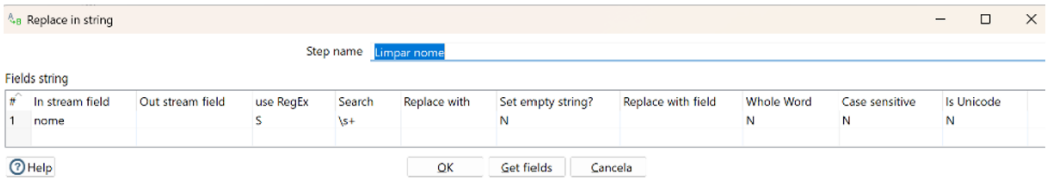


Figura 7 - Limpar nome

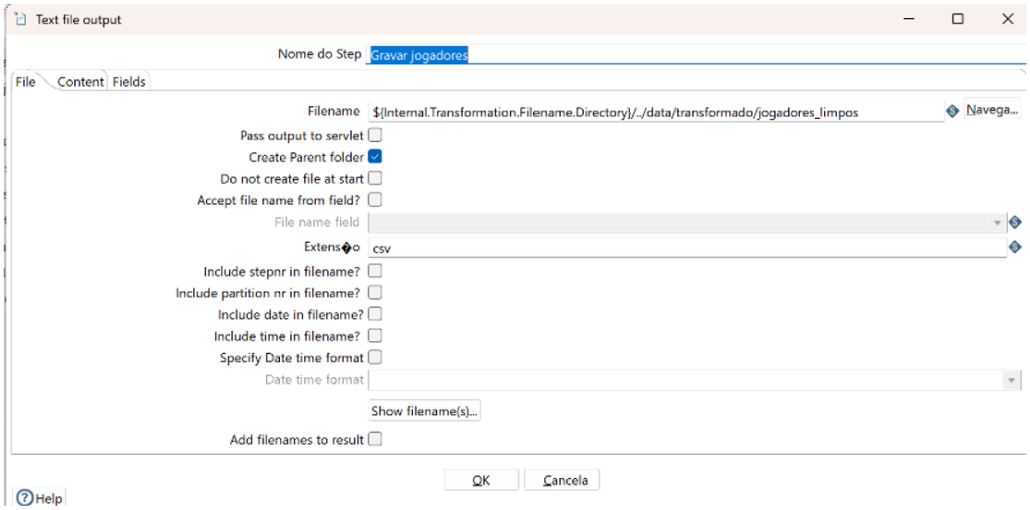


Figura 8 - Gravar jogadores

```
2026-10-12 09:59:28.251 - Fase 2 - Transformacao - Starting entry [Limpar jogadores]
2026-10-12 09:59:28.310 - Limpar jogadores - Using run configuration [Pentaho local]
2026-10-12 09:59:28.312 - limpar_jogadores - Expedindo in�cio para transforma��o [limpar_jogadores]
2026-10-12 09:59:28.334 - Ler jogadores.0 - Finished processing (I=12, O=0, R=0, W=12, U=0, E=0)
2026-10-12 09:59:28.342 - Limpar nome.0 - Finished processing (I=0, O=0, R=12, W=12, U=0, E=0)
2026-10-12 09:59:28.348 - Gravar jogadores.0 - Finished processing (I=0, O=13, R=12, W=12, U=0, E=0)
```

Figura 22 - Execution Results - Limpar Jogadores

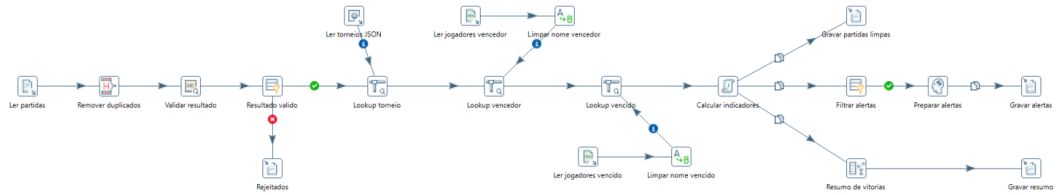


Figura 9 - Fase_2\kettle\transformar_partidas.ktr

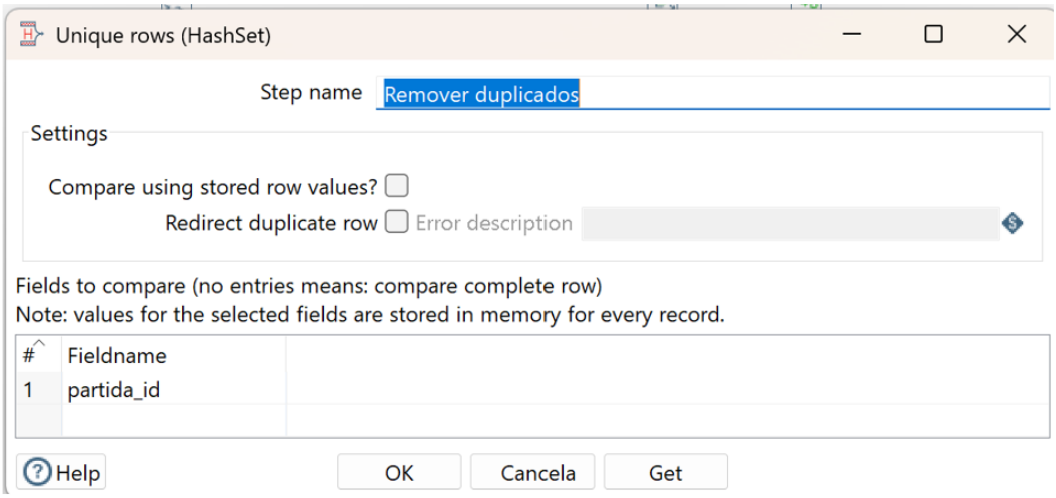


Figura 10 - Remover duplicados

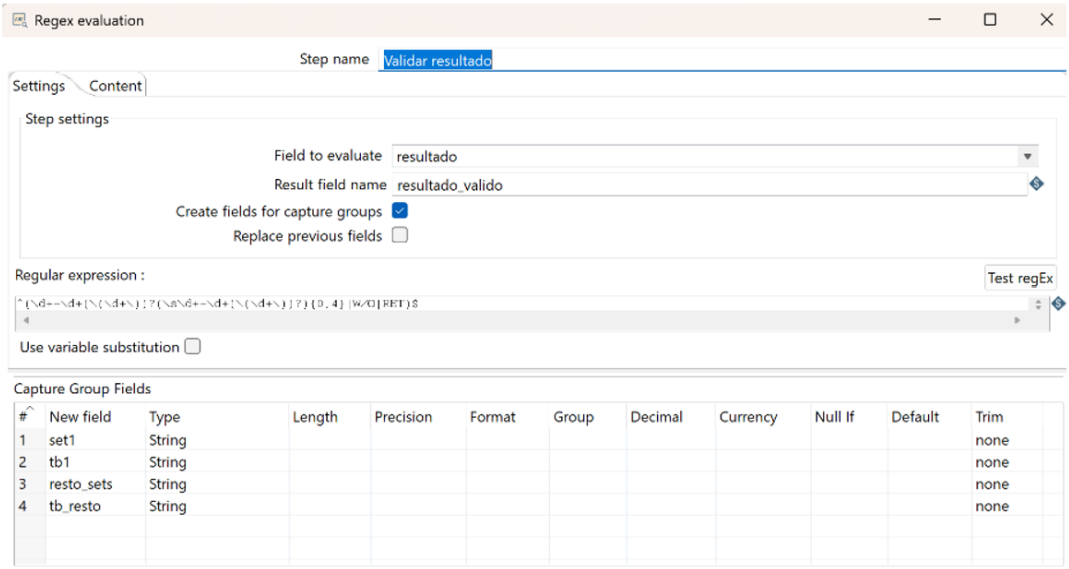


Figura 11 - Validar resultado

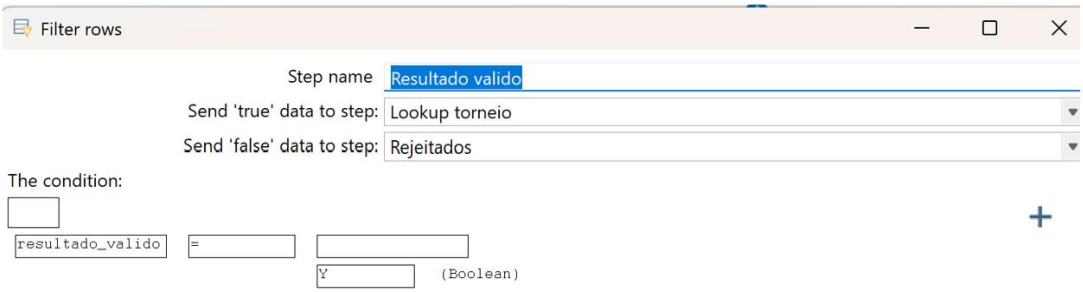


Figura 12 - Resultado valido

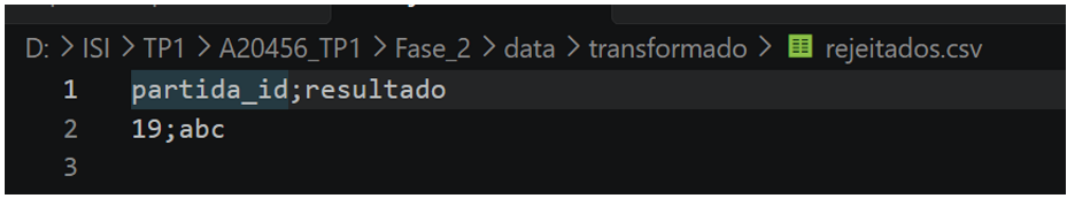


Figura 13 - Rejeitados.csv

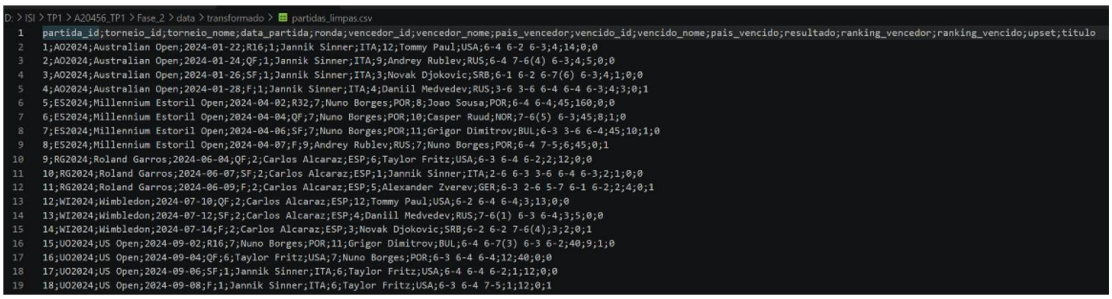


Figura 14 - Partidas limpas - 18 partidas

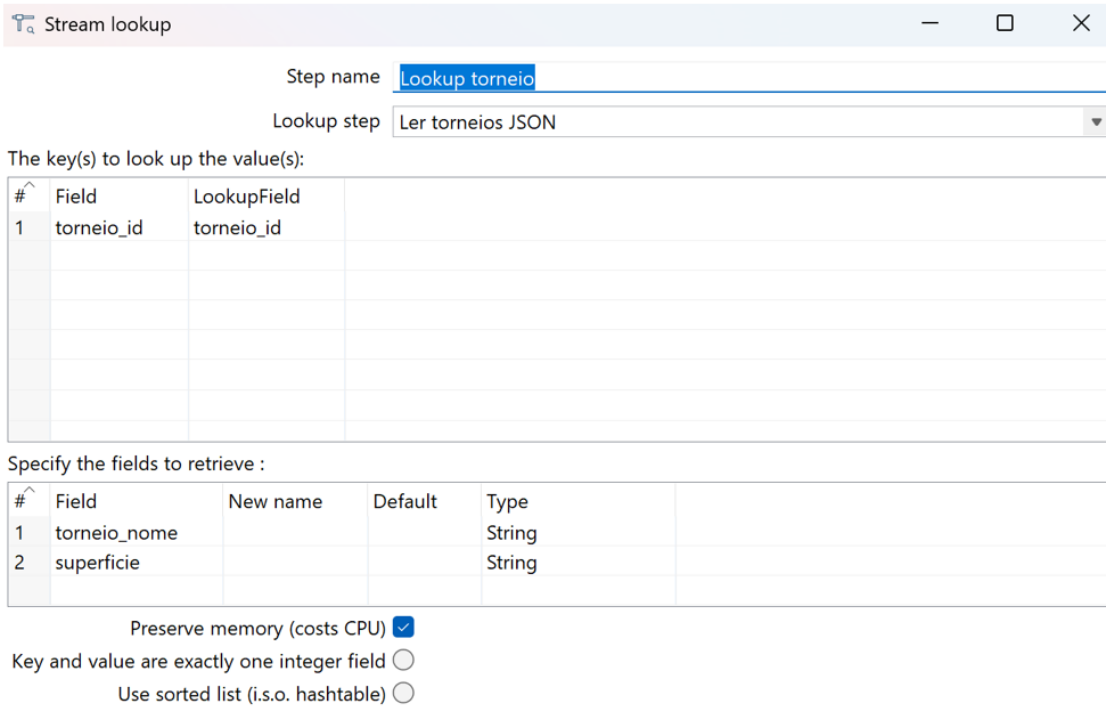


Figura 15 - Lookup torneio

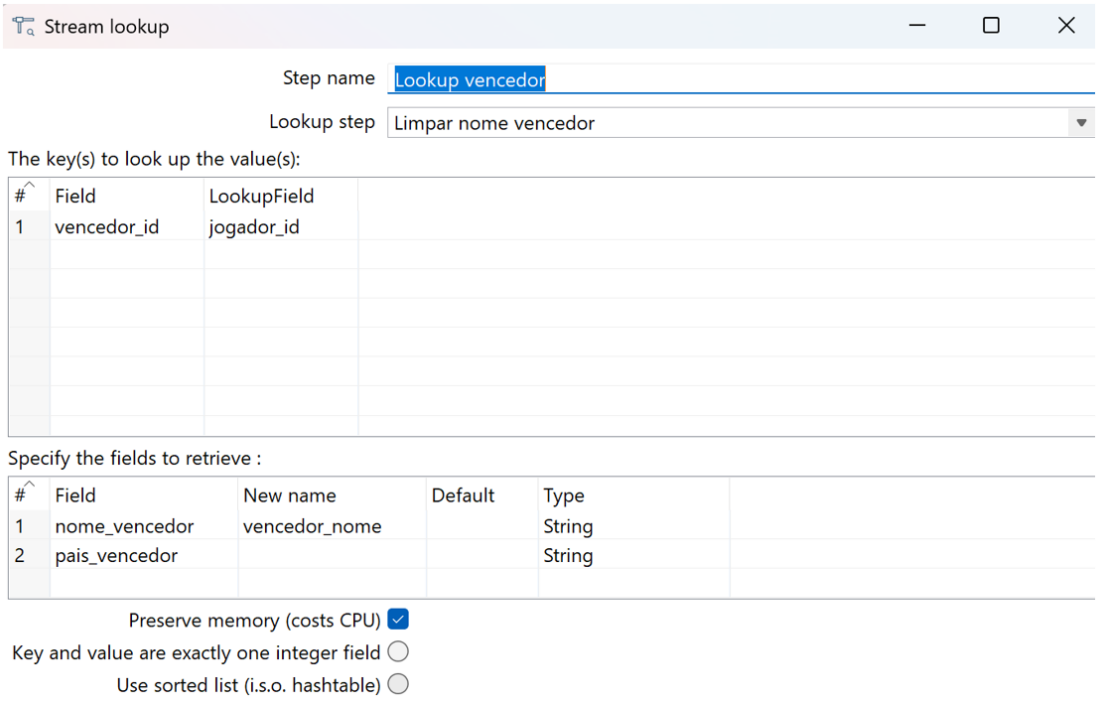


Figura 16 - Lookup vencedor

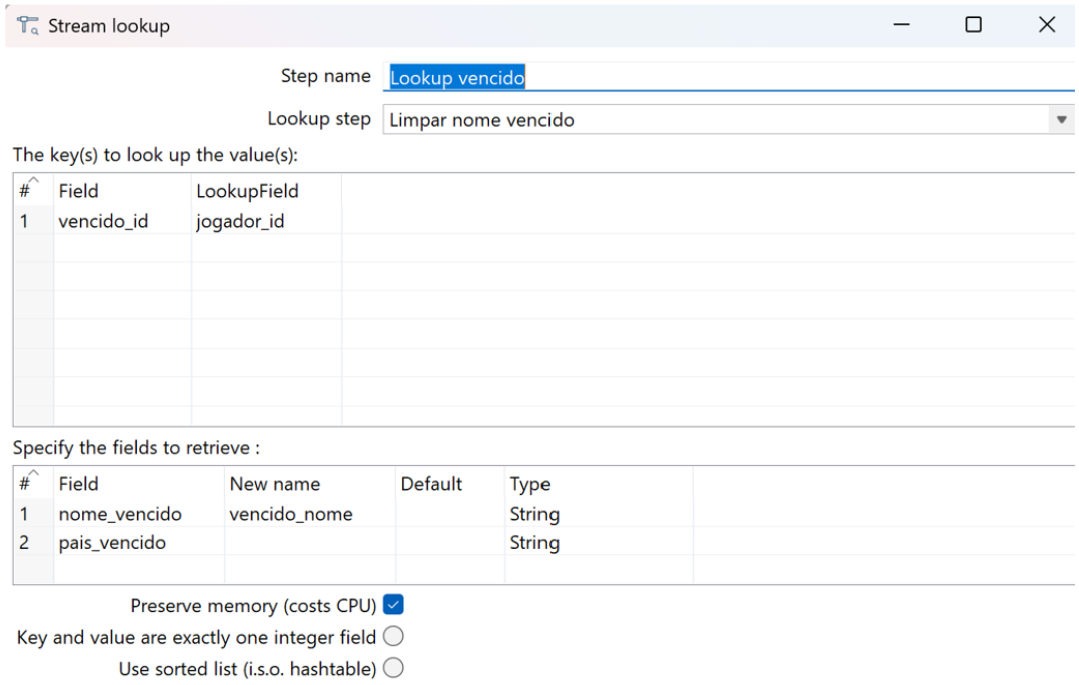


Figura 17 - Lookup vencido

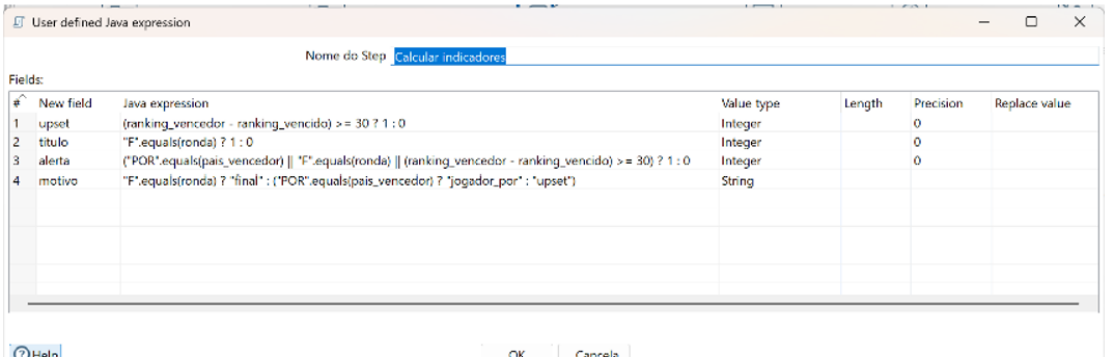


Figura 18 - Calcular indicadores



Figura 19 - Alertas.csv – 9 linhas

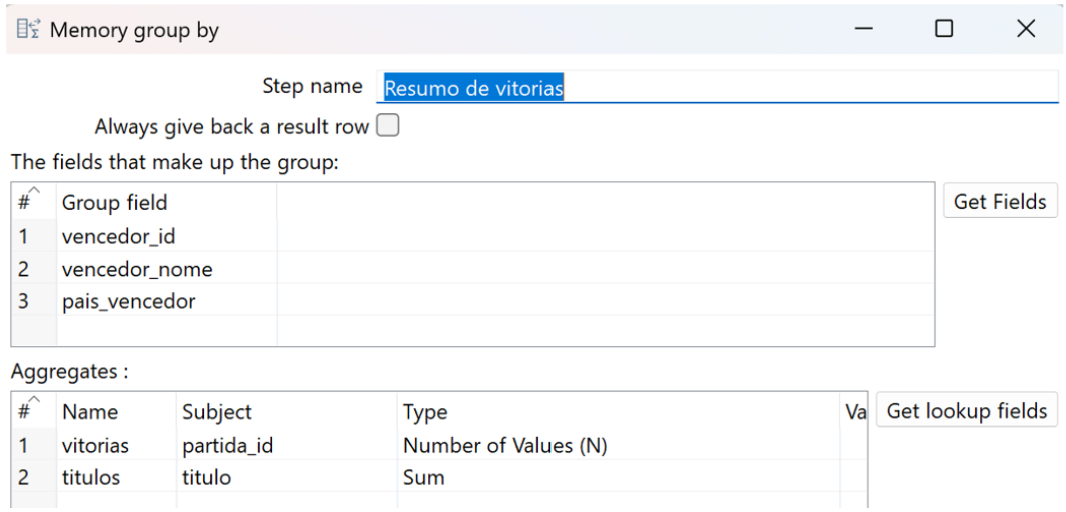


Figura 20 - Resumo de Vitorias

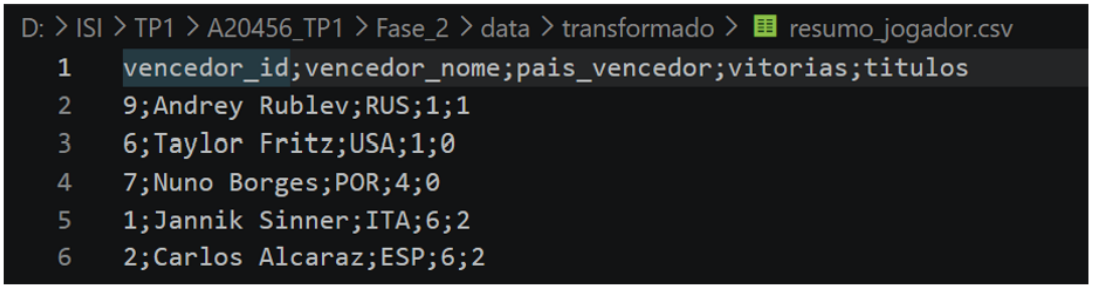


Figura 21 - Resumo_jogador.csv

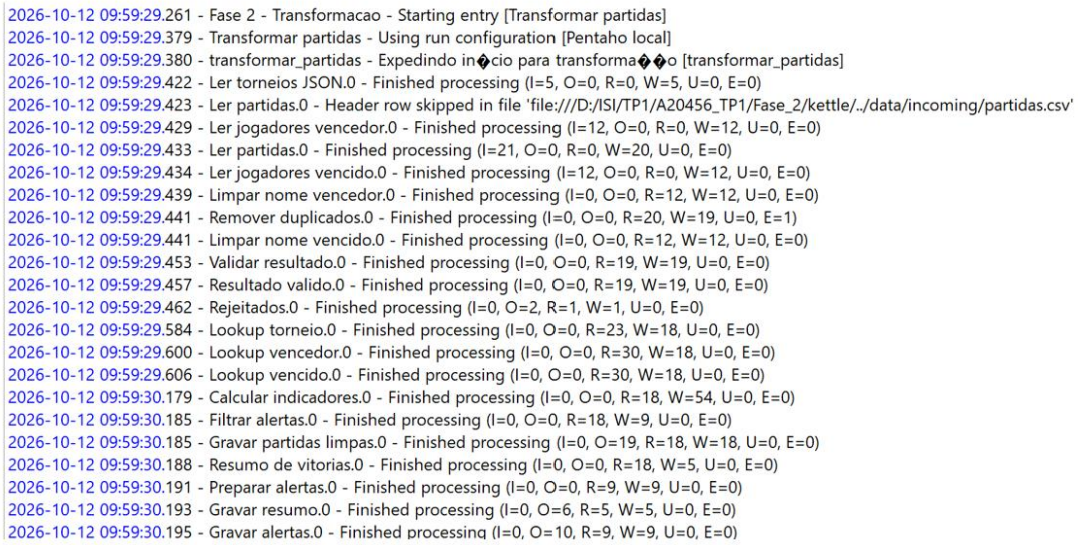


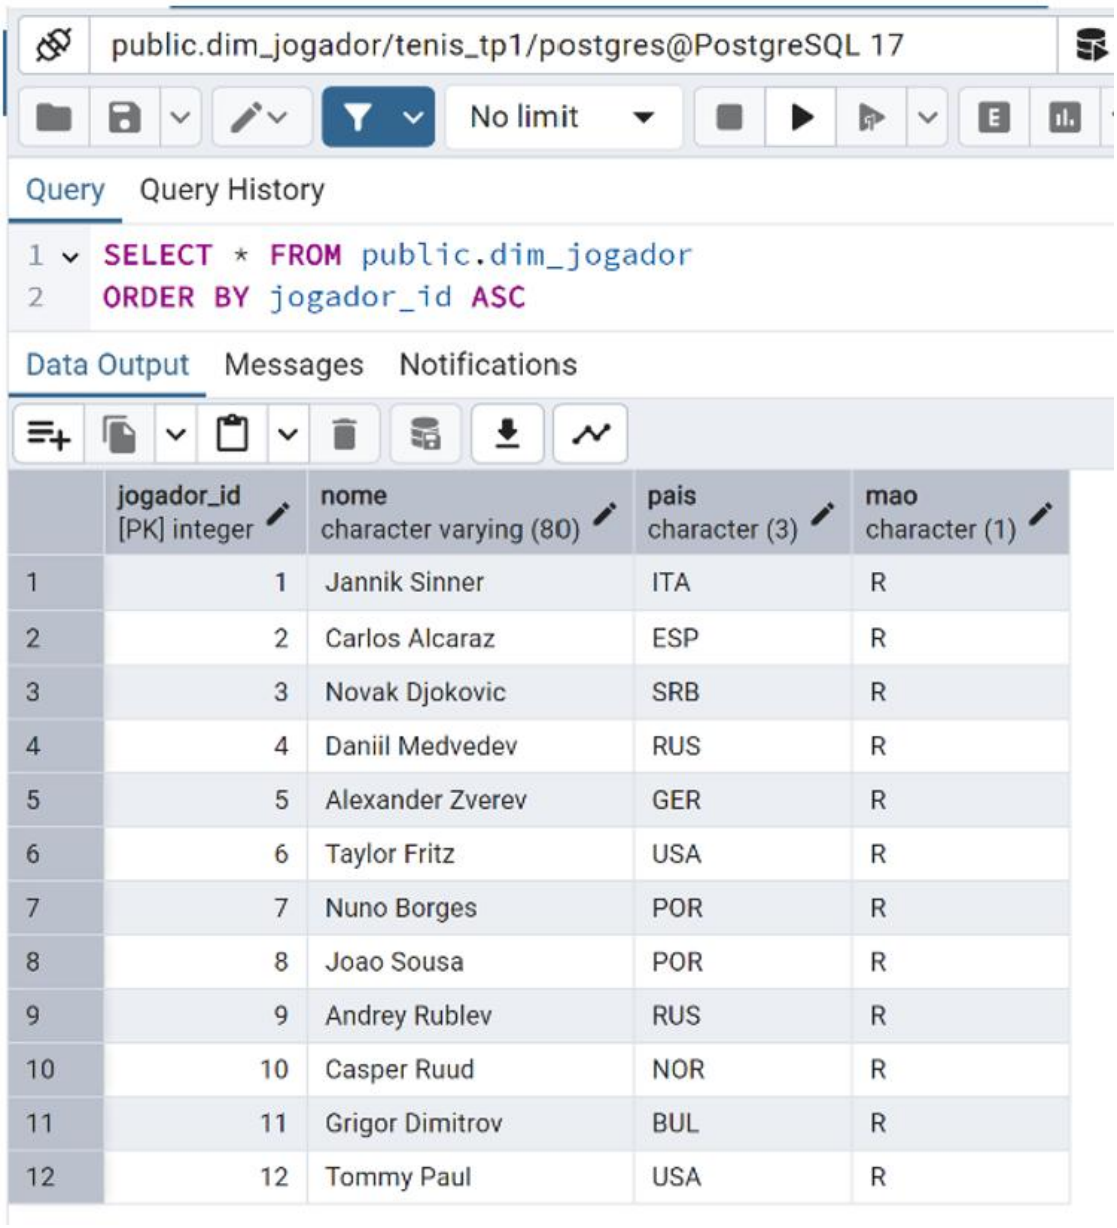
Figura 23 - Transformar Partidas

4.3. Transformações da Fase 3 (Carga, Exportação e Notificação - L)

A Fase 3 encarrega-se da carga relacional no PostgreSQL (base tenis_tp1), exportação de ficheiros externos e envio de email de confirmação:



Figura 25 - Carregar_jogadores_bd.ktr



	jogador_id [PK] integer	nome character varying (80)	pais character (3)	mao character (1)
1	1	Jannik Sinner	ITA	R
2	2	Carlos Alcaraz	ESP	R
3	3	Novak Djokovic	SRB	R
4	4	Daniil Medvedev	RUS	R
5	5	Alexander Zverev	GER	R
6	6	Taylor Fritz	USA	R
7	7	Nuno Borges	POR	R
8	8	Joao Sousa	POR	R
9	9	Andrey Rublev	RUS	R
10	10	Casper Ruud	NOR	R
11	11	Grigor Dimitrov	BUL	R
12	12	Tommy Paul	USA	R

Figura 26 - pgadmin - dim_jogador

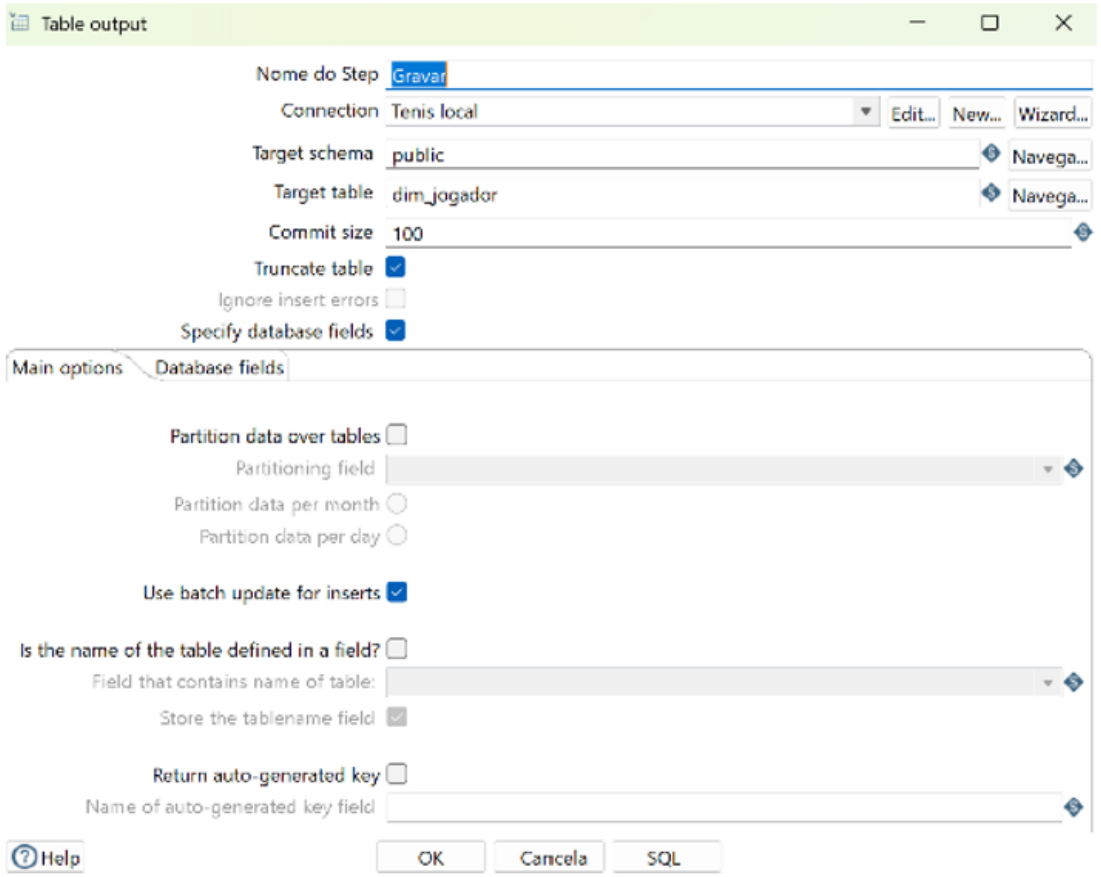


Figura 27 – Gravar em dim_jogador

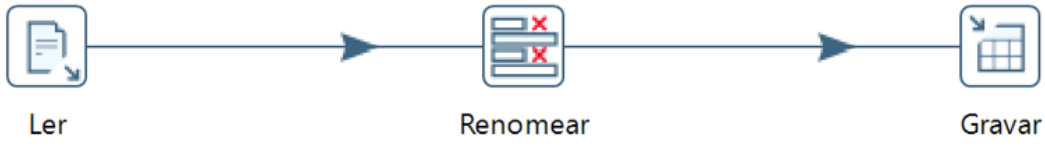


Figura 28 - carregar_torneio_bd.ktr

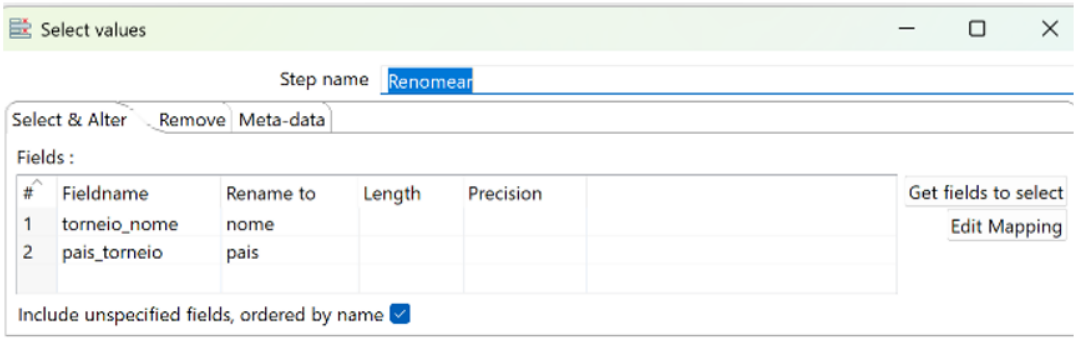
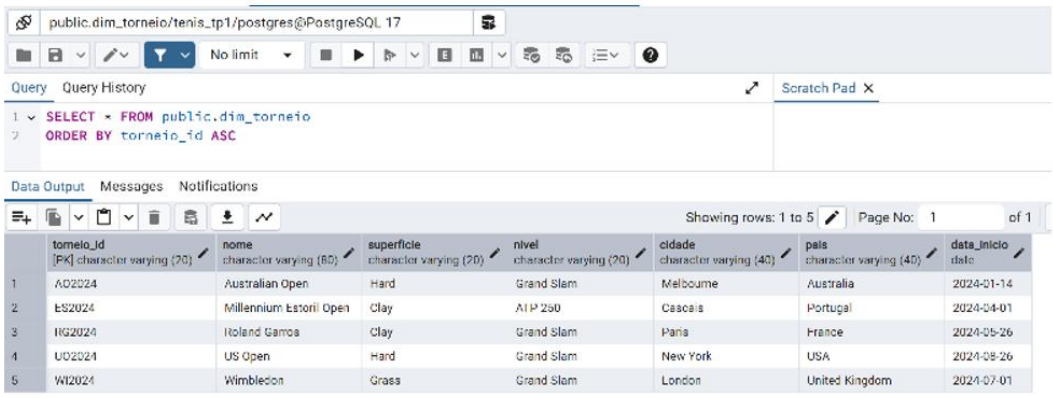


Figura 29 - Renomear



	torneio_id [PK] character varying (20)	nome character varying (80)	superficie character varying (20)	nivel character varying (20)	cidade character varying (40)	pais character varying (40)	data_inicio date
1	AO2024	Australian Open	Hard	Grand Slam	Melbourne	Australia	2024-01-14
2	ES2024	Millennium Estoril Open	Clay	ATP 250	Cascais	Portugal	2024-04-01
3	RG2024	Roland Garros	Clay	Grand Slam	Paris	France	2024-05-26
4	UO2024	US Open	Hard	Grand Slam	New York	USA	2024-08-26
5	WI2024	Wimbledon	Grass	Grand Slam	London	United Kingdom	2024-07-01

Figura 30 - dim_torneio

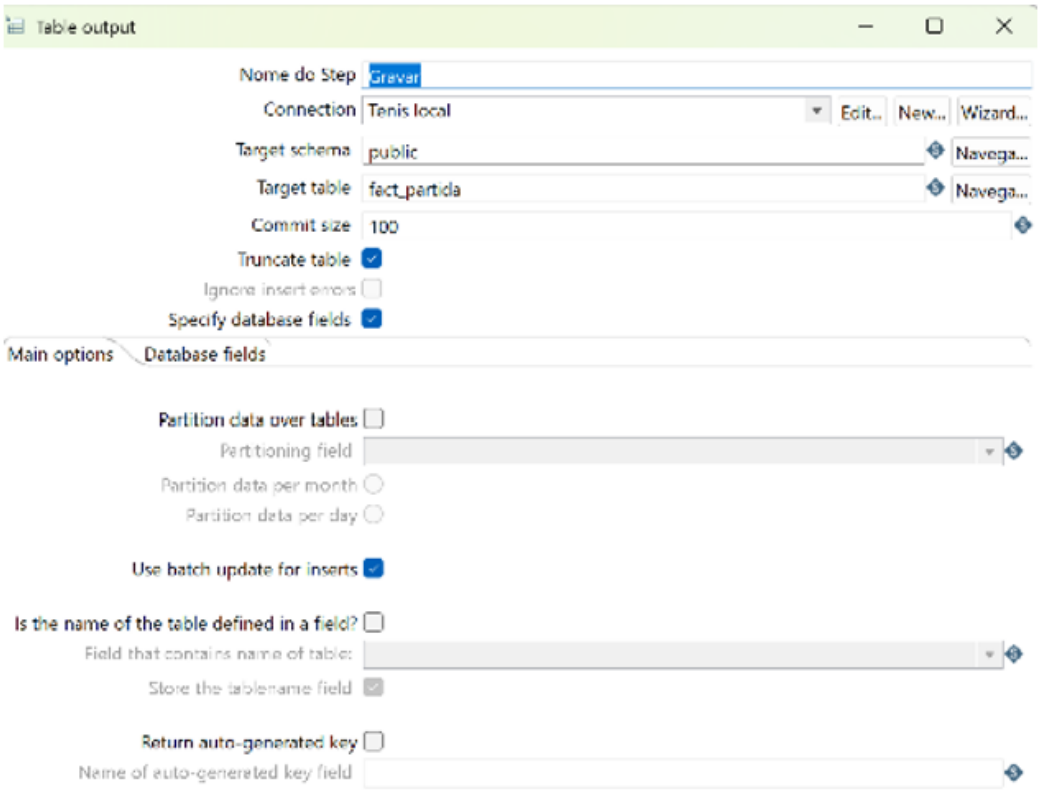


Figura 31 - Gravar em fact_partida



Figura 32 - Carregar_partidas_bd.ktr



Figura 33 - Carregar_alertas_bd.ktr

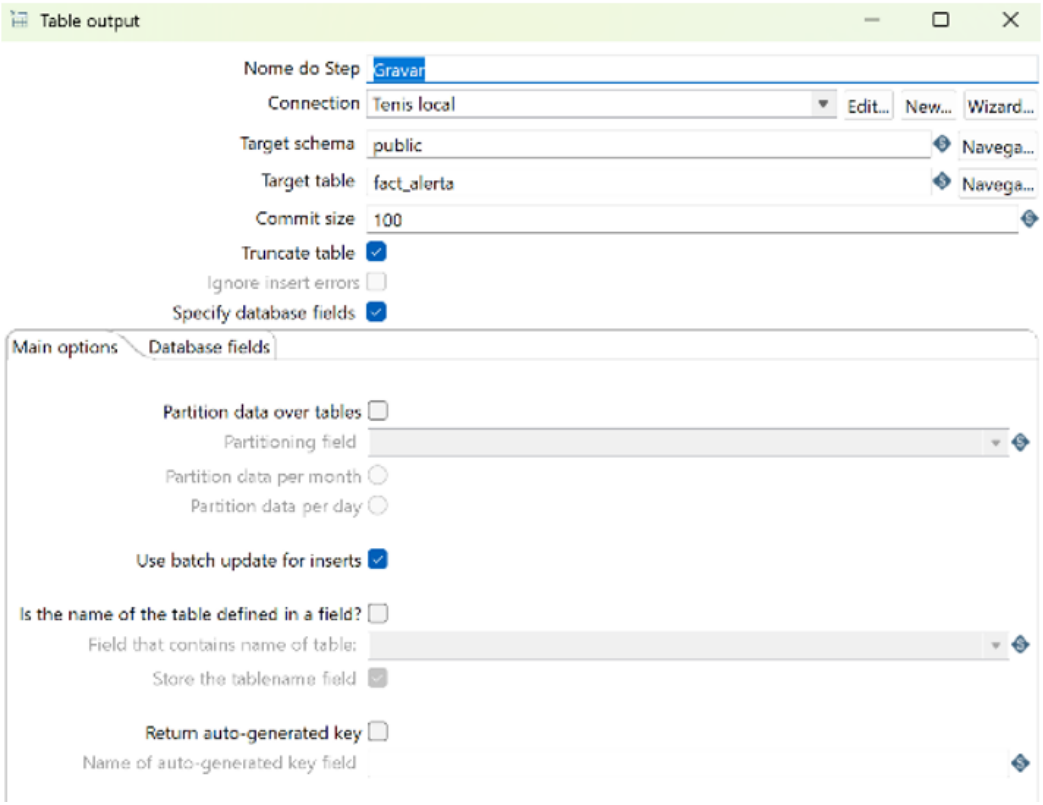
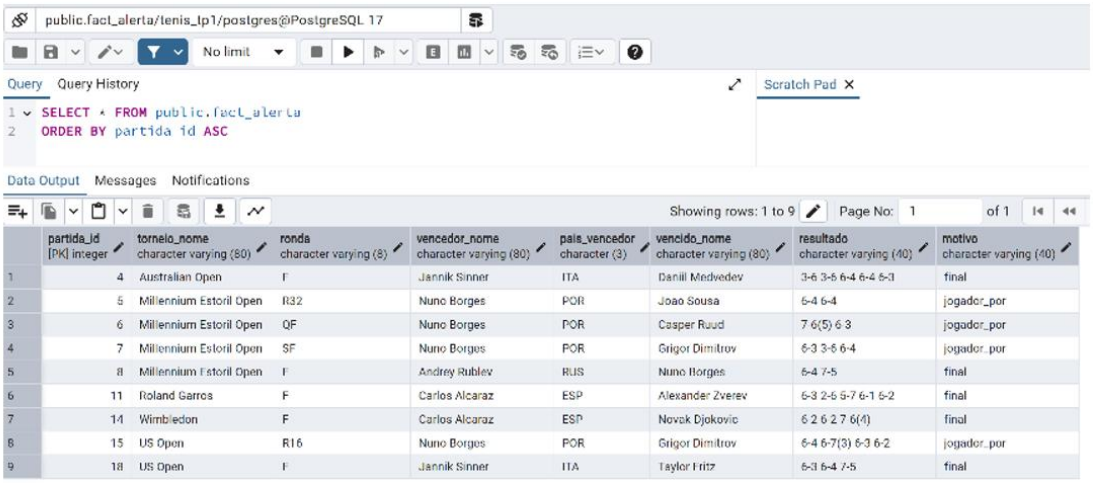


Figura 34 - Gravar em Fact_alerta



	partida_id [PK] integer	torneio_nome character varying (80)	ronda character varying (8)	vencedor_nome character varying (80)	pais_vencedor character (3)	vencido_nome character varying (80)	resultado character varying (40)	motivo character varying (40)
1	4	Australian Open	F	Jannik Sinner	ITA	Daniil Medvedev	3-6 3-6 6-4 6-4 6-3	final
2	5	Millennium Estoril Open	R32	Nuno Borges	POR	Joao Sousa	6-4 6-4	jogador_por
3	6	Millennium Estoril Open	QF	Nuno Borges	POR	Casper Ruud	7 6(5) 6 3	jogador_por
4	7	Millennium Estoril Open	SF	Nuno Borges	POR	Grigor Dimitrov	6-3 3-6 6-4	jogador_por
5	8	Millennium Estoril Open	F	Andrey Rublev	RUS	Nuno Borges	6-4 7-5	final
6	11	Roland Garros	F	Carlos Alcaraz	ESP	Alexander Zverev	6-3 2-6 6-7 6-1 6-2	final
7	14	Wimbledon	F	Carlos Alcaraz	ESP	Novak Djokovic	6 2 6 2 7 6(4)	final
8	15	US Open	R16	Nuno Borges	POR	Grigor Dimitrov	6-4 6-7(3) 6-3 6-2	jogador_por
9	18	US Open	F	Jannik Sinner	ITA	Taylor Fritz	6-3 6-4 7-5	final

Figura 35 - Pgadmin - fact_alerta



Figura 36 - carregar_resumo_bd.ktr

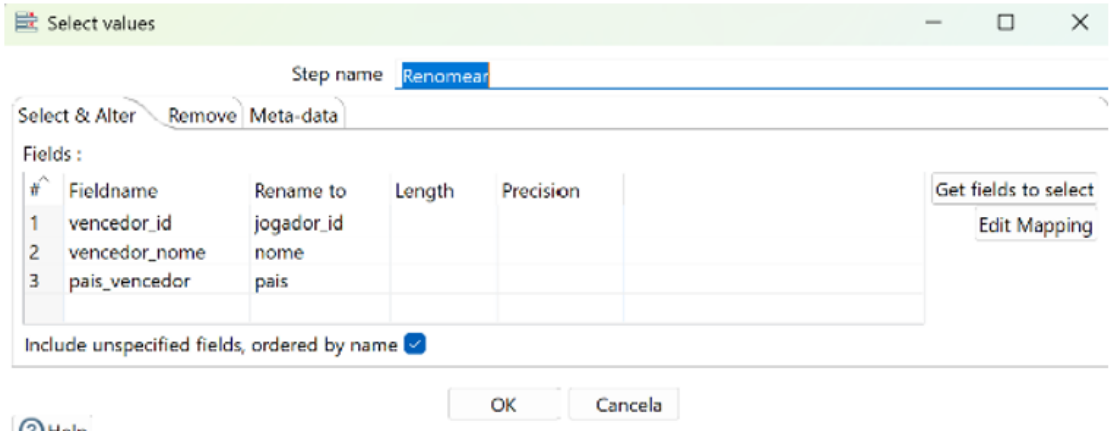
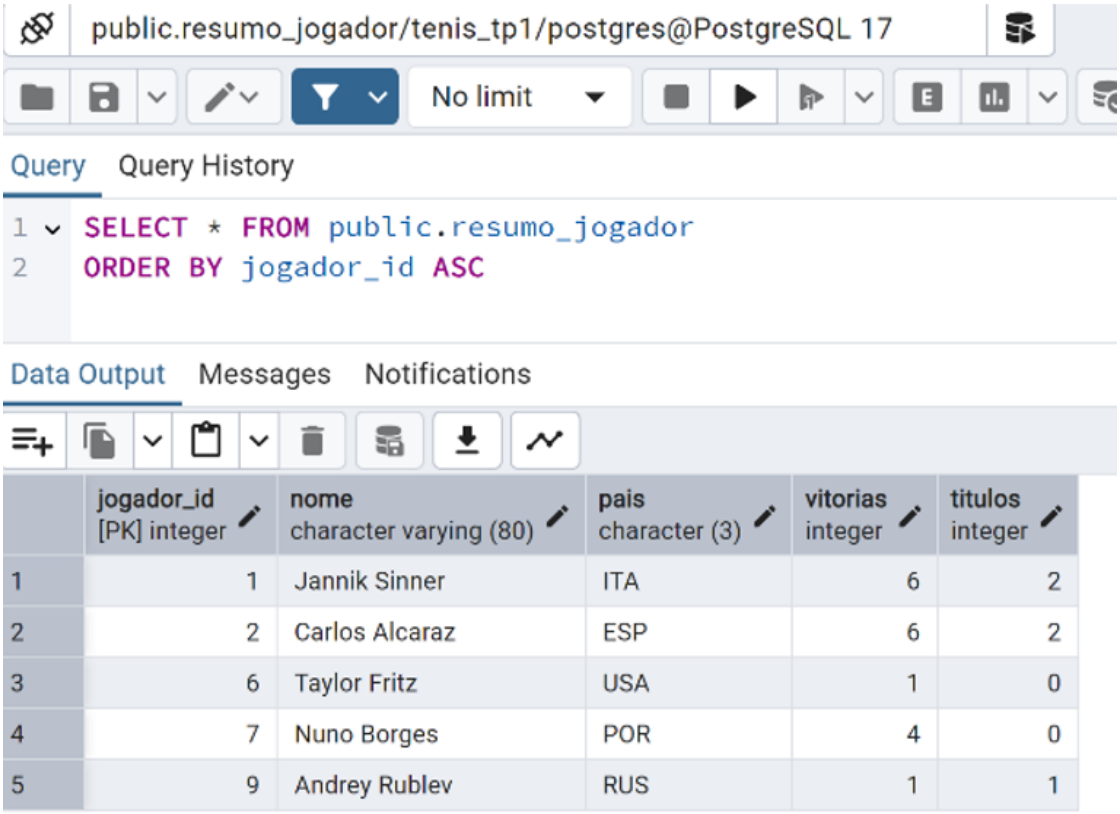


Figura 37 - Renomear



	jogador_id [PK] integer	nome character varying (80)	pais character (3)	vitorias integer	titulos integer
1	1	Jannik Sinner	ITA	6	2
2	2	Carlos Alcaraz	ESP	6	2
3	6	Taylor Fritz	USA	1	0
4	7	Nuno Borges	POR	4	0
5	9	Andrey Rublev	RUS	1	1

Figura 38 - resumo_jogador

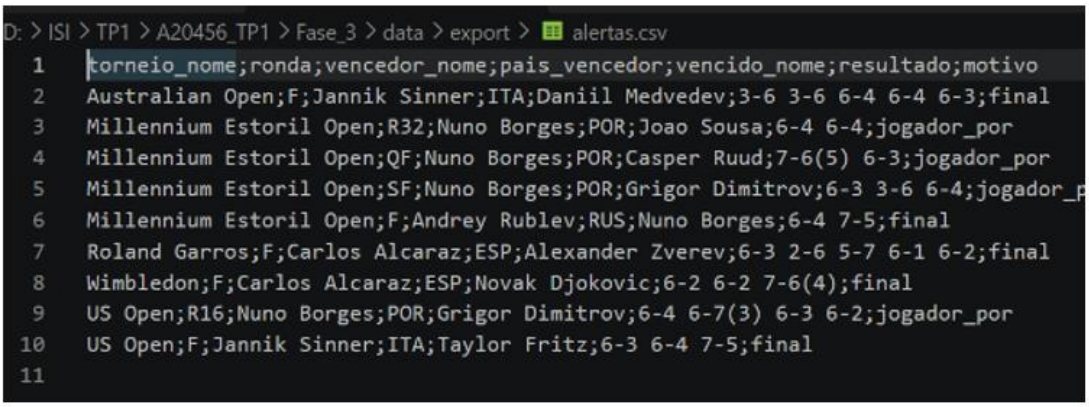


Figura 39 - Fase_3\data\export\alertas.csv



Figura 40 - exportar_alertas.ktr

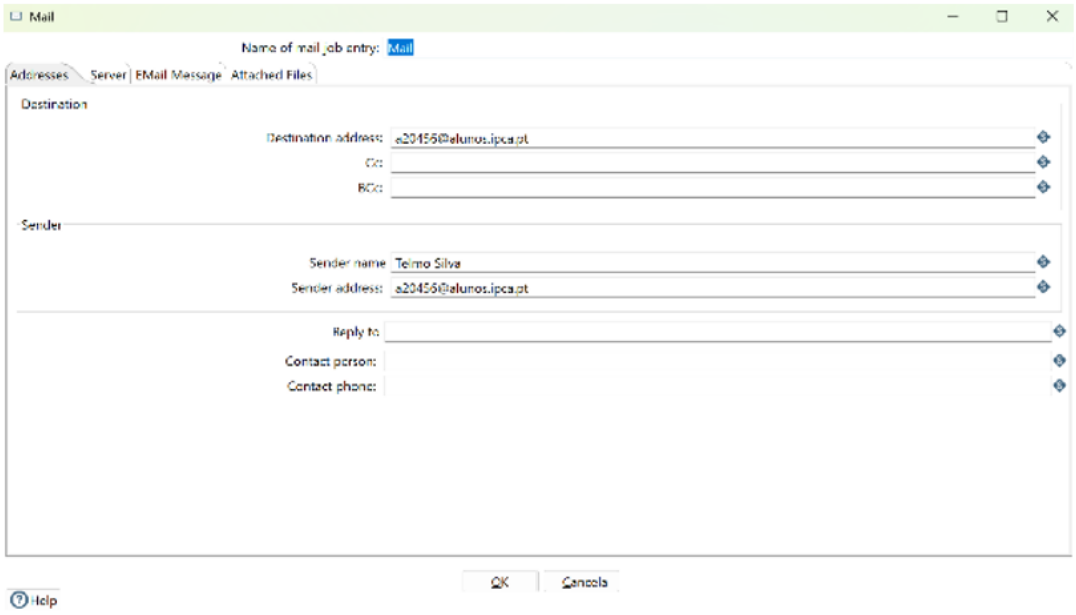


Figura 41 - Mail

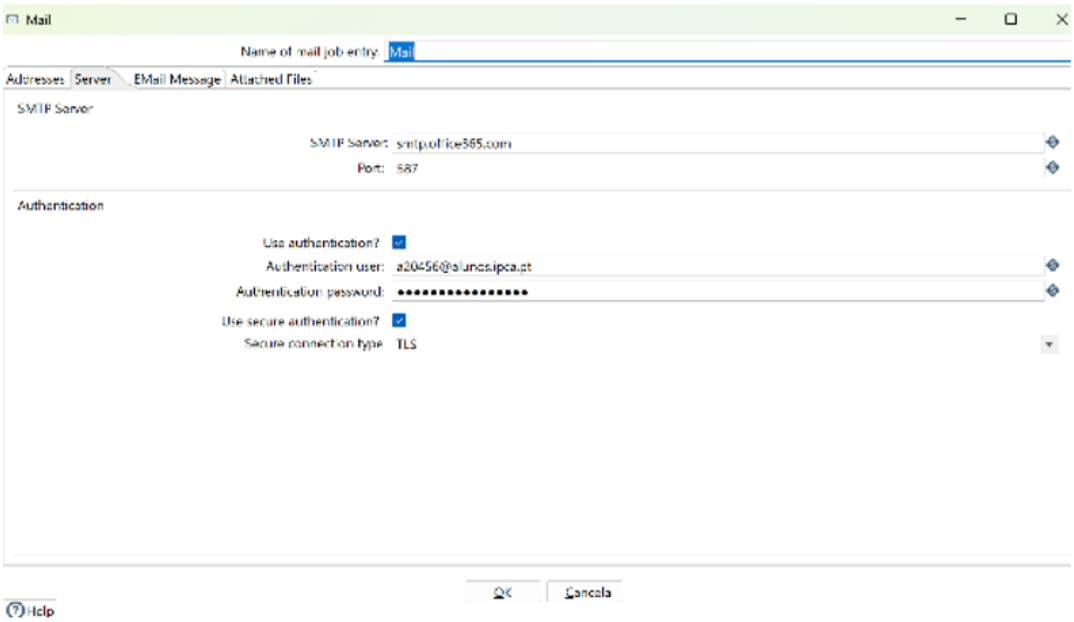


Figura 42 - Mail Server

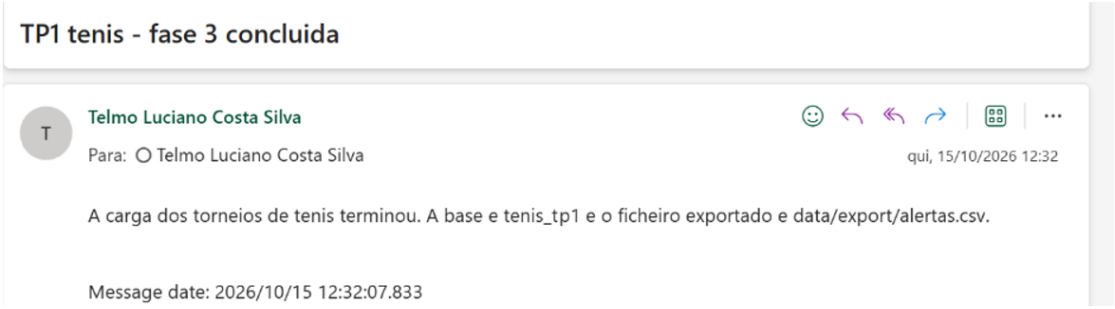


Figura 43 - Mail Recebido

5. Jobs

Os Jobs (.kjb) do Pentaho Data Integration garantem a orquestração encadeada e automatizada de todo o fluxo de trabalho.

5.1. Job da Fase 1 (job_fase1_recolha.kjb)

Orquestra a leitura encadeada das quatro fontes e o registo do log de execução em Fase_1\data\logs\execucao.log.

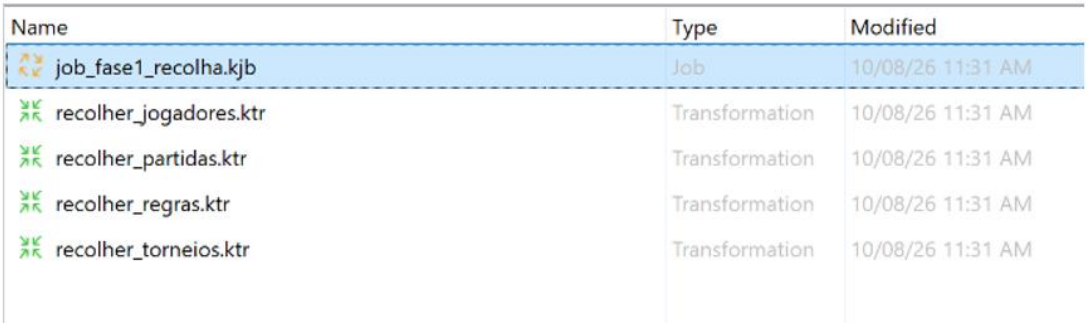


Figura 44 - job_fase1_recolha.kjb



Figura 45 - Jobs execution – Fase 1



Figura 46 - job fase1 Spoon

5.2. Job da Fase 2 (job_fase2_transformacao.kjb)

Chama a recolha da Fase 1, executa a limpeza de nomes de jogadores e processa a transformação completa das partidas.

Name	Type	Modified
job_fase1_recolha.kjb	Job	10/08/26 11:31 AM
job_fase2_transformacao.kjb	Job	10/08/26 11:31 AM
limpar_jogadores.ktr	Transformation	10/08/26 11:31 AM
recolher_jogadores.ktr	Transformation	10/08/26 11:31 AM
recolher_partidas.ktr	Transformation	10/08/26 11:31 AM
recolher_regras.ktr	Transformation	10/08/26 11:31 AM
recolher_torneios.ktr	Transformation	10/08/26 11:31 AM
transformar_partidas.ktr	Transformation	10/08/26 11:31 AM

Figura 47 - job_fase2_transformacao.kjb

Fase 2 - Transformacao			
Job: Fase 2 - Transformacao	Start of job execution		start
Start	Start of job execution		start
Start	Job execution finished	Sucesso	
Recolha da fase 1	Start of job execution		Followed unconditional link
Job: Fase 1 - Recolha			
Recolha da fase 1	Job execution finished	Sucesso	
Limpar jogadores	Start of job execution		Followed link after success
Limpar jogadores	Job execution finished	Sucesso	
Transformar partidas	Start of job execution		Followed link after success
Transformar partidas	Job execution finished	Sucesso	
Job: Fase 2 - Transformacao	Job execution finished	Sucesso	finished

Figura 48 - Jobs execution - Fase 2



Figura 49 - job fase2 Spoon

5.3. Job da Fase 3 (job_fase3_carga.kjb)

Orquestrador principal de todo o projeto. Executa a Fase 2, efetua a carga relacional em 5 tabelas no PostgreSQL, exporta ficheiro de alertas e envia email de notificação.



Figura 24 - job_fase3_carga.kjb

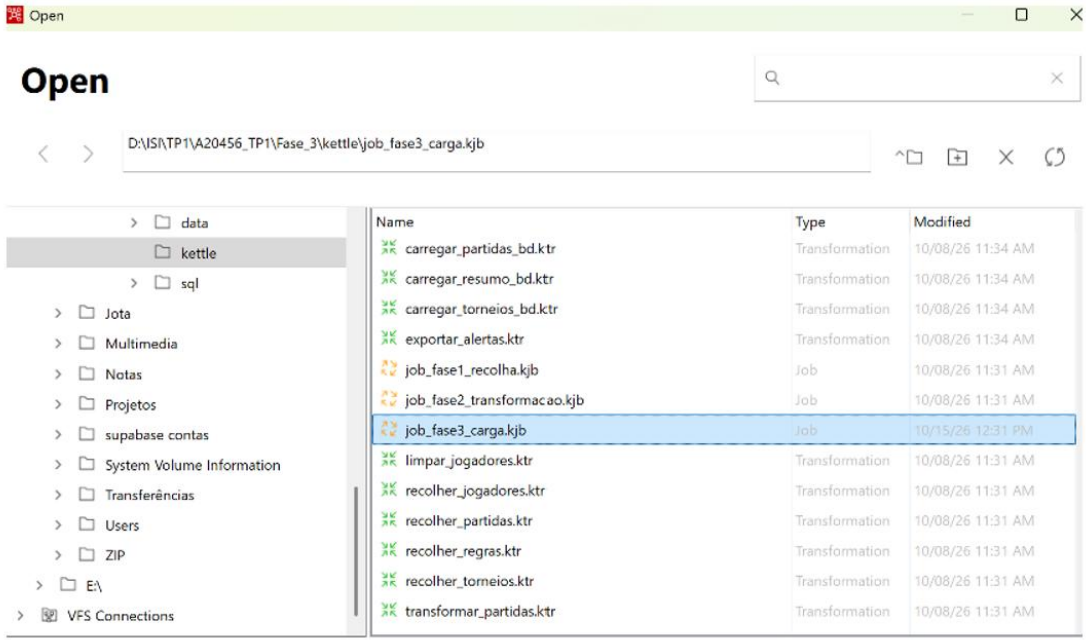


Figura 50 - job_fase3_carga.kjb



Figura 51 - Spoon job_fase3_carga.kjb



Execution Results

Logging | History | Job metrics | Metrics

Job / Entrada do Job	Coment&#65533;rio	Resultado	Raz&#65533;o
Fase 3 - Carga			
Job: Fase 3 - Carga	Start of job execution		start
Start	Start of job execution		start
Start	Job execution finished	Successo	
Transformacao da fase 2	Start of job execution		Followed unconditional link
Job: Fase 2 - Transformacao			
Transformacao da fase 2	Job execution finished	Successo	
Carregar jogadores	Start of job execution		Followed link after success
Carregar jogadores	Job execution finished	Successo	
Carregar torneios	Start of job execution		Followed link after success
Carregar torneios	Job execution finished	Successo	
Carregar partidas	Start of job execution		Followed link after success
Carregar partidas	Job execution finished	Successo	
Carregar alertas	Start of job execution		Followed link after success
Carregar alertas	Job execution finished	Successo	
Carregar resumo	Start of job execution		Followed link after success
Carregar resumo	Job execution finished	Successo	
Exportar alertas	Start of job execution		Followed link after success
Exportar alertas	Job execution finished	Successo	
Mail	Start of job execution		Followed link after success
Mail	Job execution finished	Successo	
Job: Fase 3 - Carga	Job execution finished	Successo	finished

Figura 52 - registo de execução job fase 3

6. Vídeo com demonstração (QR Code)



Figura 53 - Download Video QR Code

Ligação direta para o vídeo:

https://drive.google.com/file/d/1IJxirmKLc368iiJz2su6Sw3fbWsrXbHI/view?usp=drivesdk

Ligação direta para o repositório:

https://github.com/TelmoSilva20456/tp01-A20456

7. Conclusão e Trabalhos Futuros

O trabalho desenvolvido percorreu com sucesso todo o ciclo de vida de um projeto de ETL sobre dados de resultados de torneios de ténis. A solução desenvolvida demonstrou capacidade de lidar com a heterogeneidade de formatos (CSV, JSON, XML, YAML), sanitização de dados com expressões regulares, resolução de duplicados, cálculo de métricas de negócio (upset, títulos, alertas), persistência relacional em PostgreSQL e notificação automatizada.

7.1. Tabela de Cumprimento de Requisitos do Enunciado

Requisito do Enunciado	Implementação no Projeto	Estado
Diversidade de Formatos & Origens (E)	Ingestão de CSV, JSON, XML e YAML para staging em CSV	**Concluído**
Limpeza, Regex & Validação (T)	Unique rows, Regex em resultado e substituição \s+ em nomes	**Concluído**
Cruzamento & Agregação (T)	Stream lookup (torneios/jogadores) e Memory group by (vitórias)	**Concluído**
Persistência & Exportação (L)	Carga em 5 tabelas no PostgreSQL, exportação CSV e e-mail SMTP	**Concluído**
Orquestração Modular (Jobs)	Jobs encadeados (.kjb) para Fase 1, Fase 2 e Fase 3	**Concluído**

7.2. Trabalhos Futuros

- **Automação e Agendamento:** Integração do Job da Fase 3 em ferramentas de agendamento (ex.: Cron ou Apache Airflow) para execução periódica sem intervenção humana.
- **Dashboards em Tempo Real:** Conectividade da base PostgreSQL a ferramentas de visualização (ex.: Grafana, Power BI ou Node-RED Dashboard) para monitorização contínua de alertas e vitórias.
- **Evolução da Base de Dados:** Evolução do modelo relacional para um modelo dimensional em Estrela (Star Schema) otimizado para Data Warehousing.

8. Referências Bibliográficas

Hitachi Vantara. (s.d.). Pentaho Data Integration Documentation. Obtido de https://help.hitachivantara.com/Documentation/Pentaho/Data_Integration

PostgreSQL. (s.d.). Global Development Group. PostgreSQL 17 Documentation. Obtido de https://www.postgresql.org/docs/17/

Ferreira, L., & Ribeiro, Ó. (2026). ESI-ISI 2026-27 - TP1 - enunciado.pdf. IPCA - Escola Superior de Tecnologia.

Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3rd ed.). Wiley.

Silva, T. (2026). TP1 ISI — integração de resultados de torneios de ténis, A20456. Código-fonte. Obtido de https://github.com/TelmoSilva20456/tp01-A20456